

Efficient Low-Rank Methods for PDE-Based Inverse Problems

Forsvar av masteroppgave

Elias Jegervatn Severinsen

2026

Veiledere: Ole L. Elvetun, Jonas Kusch

Norges miljø- og biovitenskapelige universitet
Datavitenskap

Motivasjon: et PDE-basert inverst problem

Tidligere arbeid: vektet Tikhonov-regularisering

Tilnærming av foroveroperatoren: matrise-fri rSVD

Matrise-fri rSVD: resultater

Dynamisk lavrang-tilnærming (DLRA)

DLRA-CG: resultater

Konklusjon

Motivasjon: et PDE-basert inverst problem

Det inverse problemet

Betrakt problemet

$$\begin{aligned} -\nabla \cdot \sigma \nabla u + cu &= f \quad \text{i } \Omega, \\ \frac{\partial u}{\partial n} &= 0 \quad \text{på } \partial\Omega. \end{aligned}$$

- **Forover:** gitt f , finn u .
- **Inverst:** gitt rand-data $u|_{\partial\Omega}$, rekonstruer f .

Det inverse problemet


Betrakt problemet

$$\begin{aligned} -\nabla \cdot \sigma \nabla u + cu &= f \quad \text{i } \Omega, \\ \frac{\partial u}{\partial n} &= 0 \quad \text{på } \partial\Omega. \end{aligned}$$

- **Forover:** gitt f , finn u .
- **Inverst:** gitt rand-data $u|_{\partial\Omega}$, rekonstruer f .

Om vi definerer $\mathcal{K} = \mathcal{T} \circ \mathcal{S}$, med $\mathcal{T} : u \rightarrow u|_{\partial\Omega}$ og $\mathcal{S} : f \rightarrow u$, får vi formuleringen:

$$\mathcal{K}f = u|_{\partial\Omega}.$$



Utfordringen: $\mathcal{K}$ er dårlig stilt og forventningsskjev

La $K \in \mathbb{R}^{N_b \times N}$ være diskretiseringen av $\mathcal{K}$, med N noder og N_b rand-noder

- K er svært dårlig stilt, siden...

Utfordringen: $\mathcal{K}$ er dårlig stilt og forventningsskjev

La $K \in \mathbb{R}^{N_b \times N}$ være diskretiseringen av $\mathcal{K}$, med N noder og N_b rand-noder

- K er svært dårlig stilt, siden...
- K har et stort nullrom: løsningene er ikke-entydige

Utfordringen: $\mathcal{K}$ er dårlig stilt og forventningsskjev

La $K \in \mathbb{R}^{N_b \times N}$ være diskretiseringen av $\mathcal{K}$, med N noder og N_b rand-noder

- K er svært dårlig stilt, siden...
- K har et stort nullrom: løsningene er ikke-entydige
- K har raskt avtagende singularverdier: løsningene er ustabile

Utfordringen: $\mathcal{K}$ er dårlig stilt og forventningsskjev

La $K \in \mathbb{R}^{N_b \times N}$ være diskretiseringen av $\mathcal{K}$, med N noder og N_b rand-noder

- K er svært dårlig stilt, siden...
- K har et stort nullrom: løsningene er ikke-entydige
- K har raskt avtagende singularverdier: løsningene er ustabile

Tikhonov-regularisering er en standard prosedyre,

$$\min \|Kx - y\|_{M_\theta}^2 + \lambda^2 \|Wx\|_M^2,$$

men dette gir forventningsskjeve løsninger som konsentrerer seg nær randen av domenet [1].

**Tidligere arbeid: vektet
Tikhonov-regularisering**

f kan skrives som $f = f_{\perp} + f_0$. Elvetun og Nielsen viser at f nær $\partial\Omega$ har større $f_{\perp}$ -komponent:

f kan skrives som $f = f_{\perp} + f_0$. Elvetun og Nielsen viser at f nær $\partial\Omega$ har større $f_{\perp}$ -komponent:

- La $\hat{P}: V_h \rightarrow \text{Nul}(\mathcal{K})^{\perp}$

f kan skrives som $f = f_{\perp} + f_0$. Elvetun og Nielsen viser at f nær $\partial\Omega$ har større $f_{\perp}$ -komponent:

- La $\hat{P}: V_h \rightarrow \text{Nul}(\mathcal{K})^{\perp}$
- Minimum-norm-løsningen $f^* = \sum_i \langle \hat{P}f, \phi_i \rangle \phi_i$

f kan skrives som $f = f_{\perp} + f_0$. Elvetun og Nielsen viser at f nær $\partial\Omega$ har større $f_{\perp}$ -komponent:

- La $\hat{P}: V_h \rightarrow \text{Nul}(\mathcal{K})^{\perp}$
- Minimum-norm-løsningen $f^* = \sum_i \langle \hat{P}f, \phi_i \rangle \phi_i$
- $\|\hat{P}\phi_i\| = \|\phi_{i,\perp}\|$ blir liten for ϕ_i langt unna $\partial\Omega$

f kan skrives som $f = f_{\perp} + f_0$. Elvetun og Nielsen viser at f nær $\partial\Omega$ har større $f_{\perp}$ -komponent:

- La $\hat{P} : V_h \rightarrow \text{Nul}(\mathcal{K})^{\perp}$
- Minimum-norm-løsningen $f^* = \sum_i \langle \hat{P}f, \phi_i \rangle \phi_i$
- $\|\hat{P}\phi_i\| = \|\phi_{i,\perp}\|$ blir liten for ϕ_i langt unna $\partial\Omega$
- Komponentene $\langle \hat{P}f, \phi_i \rangle$ tvinges til å bli liten fra Cauchy-Schwarz

f kan skrives som $f = f_{\perp} + f_0$. Elvetun og Nielsen viser at f nær $\partial\Omega$ har større $f_{\perp}$ -komponent:

- La $\hat{P}: V_h \rightarrow \text{Nul}(\mathcal{K})^{\perp}$
- Minimum-norm-løsningen $f^* = \sum_i \langle \hat{P}f, \phi_i \rangle \phi_i$
- $\|\hat{P}\phi_i\| = \|\phi_{i,\perp}\|$ blir liten for ϕ_i langt unna $\partial\Omega$
- Komponentene $\langle \hat{P}f, \phi_i \rangle$ tvinges til å bli liten fra Cauchy-Schwarz

De retter opp i denne skjevheten ved å sette $\|\hat{P}\phi_i\| = 1$ for alle i :

$$w_i = \|K^+ K e_i\|, \quad W = \text{diag}(w_1, \dots, w_N)$$

Men denne prosedyren er beregningskrevende:

Men denne prosedyren er beregningskrevende:

- Å konstruere K krever å løse N_b lineære systemer: $\mathcal{O}(N_b N \log N)$

Men denne prosedyren er beregningskrevende:

- Å konstruere K krever å løse N_b lineære systemer: $\mathcal{O}(N_b N \log N)$
- Å finne K^+ krever en SVD, som koster $\mathcal{O}(N_b^2 N)$


Men denne prosedyren er beregningskrevende:

- Å konstruere K krever å løse N_b lineære systemer: $\mathcal{O}(N_b N \log N)$
- Å finne K^+ krever en SVD, som koster $\mathcal{O}(N_b^2 N)$
- N skalerer som $\mathcal{O}(n^2)$ i 2D, og $\mathcal{O}(n^3)$ i 3D: uegnet for store problemer

Tilnærming av foroveroperatoren: matrise-fri rSVD


Tilnærming av foroveroperatoren

K har et stort nullrom ($\text{rank}(K) = N_b$) og raskt avtagende singulærverdier:



Tilnærming av foroveroperatoren


K har et stort nullrom ($\text{rank}(K) = N_b$) og raskt avtagende singulærverdier:



- En rang- k -tilnærming $K \approx U\Sigma V^T$ kan approksimere K godt for små k

Tilnærming av foroveroperatoren


K har et stort nullrom ($\text{rank}(K) = N_b$) og raskt avtagende singulærverdier:



- En rang- k -tilnærming $K \approx U\Sigma V^T$ kan approksimere K godt for små k
- **Idé:** bruk den randomiserte SVD-en (rSVD) til å finne $U\Sigma V^T$ [2]

Tilnærming av foroveroperatoren

K har et stort nullrom ($\text{rank}(K) = N_b$) og raskt avtagende singulærverdier:



- En rang- k -tilnærming $K \approx U\Sigma V^T$ kan approksimere K godt for små k
- **Idé:** bruk den randomiserte SVD-en (rSVD) til å finne $U\Sigma V^T$ [2]
- Vektene tilnærmes via $w_i = \|K^+ K e_i\| \approx \|V V^T e_i\|$

En matrise-fri rSVD

Den klassiske rSVD-en finner $K \approx U\Sigma V^T$:

Den klassiske rSVD-en finner $K \approx U\Sigma V^T$:

- Sampling: $Y = K\Psi$

En matrise-fri rSVD

Den klassiske rSVD-en finner $K \approx U\Sigma V^T$:

- Sampling: $Y = K\Psi$
- Range-tilnærming: $QR = Y$

Den klassiske rSVD-en finner $K \approx U\Sigma V^T$:

- Sampling: $Y = K\Psi$
- Range-tilnærming: $QR = Y$
- SVD-tilnærming: $B = Q^TK$, $QQ^TK = QB = (Q\tilde{U})\Sigma V^T = U\Sigma V^T$

Den klassiske rSVD-en finner $K \approx U\Sigma V^T$:

- Sampling: $Y = K\Psi$
- Range-tilnærming: $QR = Y$
- SVD-tilnærming: $B = Q^TK$, $QQ^TK = QB = (Q\tilde{U})\Sigma V^T = U\Sigma V^T$

Hvordan finner vi $B = Q^TK$ om vi ikke har K ?

Den klassiske rSVD-en finner $K \approx U\Sigma V^T$:

- Sampling: $Y = K\Psi$
- Range-tilnærming: $QR = Y$
- SVD-tilnærming: $B = Q^TK$, $QQ^TK = QB = (Q\tilde{U})\Sigma V^T = U\Sigma V^T$

Hvordan finner vi $B = Q^TK$ om vi ikke har K ?

- Bruk identiteten $K = M_{\partial}^{-1}(K^*)^TM$

Den klassiske rSVD-en finner $K \approx U\Sigma V^T$:

- Sampling: $Y = K\Psi$
- Range-tilnærming: $QR = Y$
- SVD-tilnærming: $B = Q^TK$, $QQ^TK = QB = (Q\tilde{U})\Sigma V^T = U\Sigma V^T$

Hvordan finner vi $B = Q^TK$ om vi ikke har K ?

- Bruk identiteten $K = M_{\partial}^{-1}(K^*)^TM$
- Det gir $B = (K^*M_{\partial}^{-1}Q)^TM$

Den klassiske rSVD-en finner $K \approx U\Sigma V^T$:



- Sampling: $Y = K\Psi$
- Range-tilnærming: $QR = Y$
- SVD-tilnærming: $B = Q^TK$, $QQ^TK = QB = (Q\tilde{U})\Sigma V^T = U\Sigma V^T$

Hvordan finner vi $B = Q^TK$ om vi ikke har K ?

- Bruk identiteten $K = M_{\partial}^{-1}(K^*)^TM$
- Det gir $B = (K^*M_{\partial}^{-1}Q)^TM$
- Matrise-fri rSVD: $K \approx U\Sigma V^T$ ved å anvende K og K^* $l = k + p$ ganger


Matrise-fri rSVD: resultater

rSVD: beregningstid



rSVD versus å danne K eksplisitt (t_K) og å finne dens SVD (t_{SVD}).

rSVD: vektete Tikhonov-løsninger



Vektete Tikhonov-løsninger med eksakt K og W (venstre), en rang-10-rSVD-tilnærming av K og W (midten), og en rang-50-rSVD-tilnærming (høyre).

Vi målte feilen ved bruk av

Vi målte feilen ved bruk av

- Euklidisk norm: måler elementvis amplitude

Vi målte feilen ved bruk av

- Euklidisk norm: måler elementvis amplitude
- Earth mover's distance (EMD): måler forskjell i “massene”


Vi målte feilen ved bruk av

- Euklidisk norm: måler elementvis amplitude
- Earth mover's distance (EMD): måler forskjell i “massene”
- AUC-IoU: måler overlapp

rSVD: evalueringsmetrikker


Vi målte feilen ved bruk av

- Euklidisk norm: måler elementvis amplitude
- Earth mover's distance (EMD): måler forskjell i “massene”
- AUC-loU: måler overlapp




Euklidisk norm (venstre), EMD (midten), og AUC-loU (høyre).

Dynamisk lavrang-tilnærming (DLRA)




f er ofte “sparse”, og vi kan ofte forvente at $X = \text{mat}(x)$ har $r = \text{rank}(X) \ll N = n^2$:



f er ofte “sparse”, og vi kan ofte forvente at $X = \text{mat}(x)$ har $r = \text{rank}(X) \ll N = n^2$:

- $X = \sum_{i=1}^r \sigma_i u_i v_i^T$: f er en sum av ytre-produkter, parametrisert av $u_i, v_i \in \mathbb{R}^n$



f er ofte “sparse”, og vi kan ofte forvente at $X = \text{mat}(x)$ har $r = \text{rank}(X) \ll N = n^2$:

- $X = \sum_{i=1}^r \sigma_i u_i v_i^T$: f er en sum av ytre-produkter, parametrisert av $u_i, v_i \in \mathbb{R}^n$
- **Idé:** Let kun etter $X \in \mathcal{M}_r$ hvor $\mathcal{M}_r$ er settet av alle rang- r -matriser

Vi definerer kostnadsfunksjonen $\Phi : \mathbb{R}^{n \times n} \rightarrow \mathbb{R}$,

$$\Phi(X) = \frac{1}{2} \|KX - y\|_{M_\partial}^2 + \frac{\lambda^2}{2} \|WX\|_M^2$$

Vi definerer kostnadsfunksjonen $\Phi : \mathbb{R}^{n \times n} \rightarrow \mathbb{R}$,

$$\Phi(X) = \frac{1}{2} \|KX - y\|_{M_\partial}^2 + \frac{\lambda^2}{2} \|WX\|_M^2$$

Vi ønsker å minimere Φ under betingelsen $X \in \mathcal{M}_r$,

$$\min_{X \in \mathbb{R}^{n \times n}} \Phi(X) \quad \text{s.t.} \quad X \in \mathcal{M}_r$$

Lavrang-formuleringen

Vi definerer kostnadsfunksjonen $\Phi : \mathbb{R}^{n \times n} \rightarrow \mathbb{R}$,


$$\Phi(X) = \frac{1}{2} \|KX - y\|_{M_\partial}^2 + \frac{\lambda^2}{2} \|WX\|_M^2$$

Vi ønsker å minimere Φ under betingelsen $X \in \mathcal{M}_r$,

$$\min_{X \in \mathbb{R}^{n \times n}} \Phi(X) \quad \text{s.t.} \quad X \in \mathcal{M}_r$$


Dynamisk lavrang-tilnærming (DLRA) er en naturlig metode for denne problemstillingen [3].

Dynamisk lavrang-tilnærming (DLRA)




Dynamisk lavrang-tilnærming (DLRA)

- Søkeretning $D^{(i)}$, steglengde α_i




Dynamisk lavrang-tilnærming (DLRA)

- Søkeretning $D^{(i)}$, steglengde α_i
- $X^{(i+1)} = X^{(i)} + \alpha_i \mathcal{P}_{X^{(i)}}(D^{(i)})$




Dynamisk lavrang-tilnærming (DLRA)

- Søkeretning $D^{(i)}$, steglengde α_i
- $X^{(i+1)} = X^{(i)} + \alpha_i \mathcal{P}_{X^{(i)}}(D^{(i)})$
- $\mathcal{P}_{X^{(i)}}(D^{(i)})$ er en projeksjon til planet $\mathcal{T}_{X^{(i)}}(\mathcal{M}_r)$




Dynamisk lavrang-tilnærming (DLRA)

- Søkeretning $D^{(i)}$, steglengde α_i
- $X^{(i+1)} = X^{(i)} + \alpha_i \mathcal{P}_{X^{(i)}}(D^{(i)})$
- $\mathcal{P}_{X^{(i)}}(D^{(i)})$ er en projeksjon til planet $\mathcal{T}_{X^{(i)}}(\mathcal{M}_r)$
- **Men:** DLRA konvergerer sakte for $D^{(i)} = -\nabla\Phi$



Dynamisk lavrang-tilnærming (DLRA)

- Søkeretning $D^{(i)}$, steglengde α_i
- $X^{(i+1)} = X^{(i)} + \alpha_i \mathcal{P}_{X^{(i)}}(D^{(i)})$
- $\mathcal{P}_{X^{(i)}}(D^{(i)})$ er en projeksjon til planet $\mathcal{T}_{X^{(i)}}(\mathcal{M}_r)$
- **Men:** DLRA konvergerer sakte for $D^{(i)} = -\nabla\Phi$
- **Løsning:** Φ er kvadratisk med SPD Hessian; hva om vi velger $\{D^{(i)}\}$ ved bruk av konjugerte gradienter (CG) i stedet?



DLRA med konjugerte gradienter (DLRA-CG)

Vi bytter ut $D^{(i)} = -\nabla\Phi$ med $\{D^{(i)}\}$ fra CG i DLRA-metoden til Schotthöfer et al [4]:

DLRA med konjugerte gradienter (DLRA-CG)

Vi bytter ut $D^{(i)} = -\nabla\Phi$ med $\{D^{(i)}\}$ fra CG i DLRA-metoden til Schotthöfer et al [4]:

$$\alpha_i = \frac{\|G^{(i)}\|_F^2}{\langle D^{(i)}, HD^{(i)} \rangle_F}, \quad D^{(i+1)} = -G^{(i+1)} + \beta_i D^{(i)}, \quad \beta_i = \frac{\|G^{(i+1)}\|_F^2}{\|G^{(i)}\|_F^2}$$

hvor $G^{(i)} = \nabla\Phi$.

DLRA med konjugerte gradienter (DLRA-CG)

Vi bytter ut $D^{(i)} = -\nabla\Phi$ med $\{D^{(i)}\}$ fra CG i DLRA-metoden til Schotthöfer et al [4]:

$$\alpha_i = \frac{\|G^{(i)}\|_F^2}{\langle D^{(i)}, HD^{(i)} \rangle_F}, \quad D^{(i+1)} = -G^{(i+1)} + \beta_i D^{(i)}, \quad \beta_i = \frac{\|G^{(i+1)}\|_F^2}{\|G^{(i)}\|_F^2}$$

hvor $G^{(i)} = \nabla\Phi$.

- Vi foreslår også en prekondisjonert variant (DLRA-PCG) for å akselerere konvergens

DLRA med konjugerte gradienter (DLRA-CG)

Vi bytter ut $D^{(i)} = -\nabla\Phi$ med $\{D^{(i)}\}$ fra CG i DLRA-metoden til Schotthöfer et al [4]:


$$\alpha_i = \frac{\|G^{(i)}\|_F^2}{\langle D^{(i)}, HD^{(i)} \rangle_F}, \quad D^{(i+1)} = -G^{(i+1)} + \beta_i D^{(i)}, \quad \beta_i = \frac{\|G^{(i+1)}\|_F^2}{\|G^{(i)}\|_F^2}$$

hvor $G^{(i)} = \nabla\Phi$.

- Vi foreslår også en prekondisjonert variant (DLRA-PCG) for å akselerere konvergens
- Restartet CG finner $G^{(i)} = \nabla\Phi$ på nytt hver N_r -te iterasjon


DLRA-CG: resultater

DLRA-CG: antall iterasjoner



Relativ feil versus antall iterasjoner for DLRA ved bruk av ulike $D^{(i)}$.

DLRA-CG: lavrang-løsninger



En rang-1-løsning (venstre) og en rang-2-løsning (høyre). Sanne løsninger markert som hvite kvadrater.

Konklusjon

- Matrise-fri rSVD løser problemer som tidligere var beregningsmessig uegnet, med liten forskjell i kvaliteten på løsningene
- DLRA-CG akselererer konvergens betydelig, og finner lavrang-løsninger med lavere feil enn fullrang-løsninger

Takk. Spørsmål?


References

- [1] O. L. Elvetun and B. F. Nielsen. ***A Regularization Operator for Source Identification for Elliptic PDEs***. 2020. DOI: 10.48550/arXiv.2005.09444. arXiv: 2005.09444 [math]. (Visited on 01/14/2026).
- [2] N. Halko, P. G. Martinsson, and J. A. Tropp. **“Finding Structure with Randomness: Probabilistic Algorithms for Constructing Approximate Matrix Decompositions”**. In: *SIAM Review* 53.2 (2011), pp. 217–288. ISSN: 0036-1445. DOI: 10.1137/090771806. (Visited on 10/08/2025).

- [3] O. Koch and C. Lubich. “**Dynamical Low-rank Approximation**”. In: *SIAM Journal on Matrix Analysis and Applications* 29.2 (2007), pp. 434–454. DOI: 10.1137/050639703.
- [4] S. Schotthöfer, E. Zangrando, J. Kusch, G. Ceruti, and F. Tudisco. ***Low-Rank Lottery Tickets: Finding Efficient Low-Rank Neural Networks via Matrix Differential Equations***. 2022. DOI: 10.48550/arXiv.2205.13571. arXiv: 2205.13571 [cs]. (Visited on 03/20/2026).


Appendiks

Appendiks i




Valg av fordelingen til ψ i samplingssteget $K\psi$ kan forbedre rang- k -tilnærmingen til K .

Appendiks ii




Oppløsningen N til meshet påvirker ikke valg av k .

Appendiks iii





Valg av k fungerer som regularisering for problemer med støy, på samme måte som trunkert SVD. Fra venstre til høyre: $k = 20, 60, 150$.

Appendiks iv



Feil valg av løsnings-rangen r kan introdusere uønskede kilder.

Appendiks v



Prekondisjonert CG akselererer konvergensen ytterligere.